

# Dystrybuanta rozkładu chi kwadrat

Zadanie nr 3

Antoni Pokusiński

## Wprowadzenie

Rozkład chi kwadrat z  $k$  stopniami swobody definiuje się jako sumę kwadratów  $k$  niezależnych zmiennych losowych, które podlegają rozkładowi  $N(0, 1)$ . Niech  $X_1, \dots, X_k$  będą niezależnymi zmiennymi losowymi oraz  $X_i \sim N(0, 1)$ . Jeśli  $Z$  to zmienna losowa, taka że

$$Z = \sum_{i=1}^k (X_i)^2$$

to wówczas:

$$Z \sim \chi^2(k)$$

Funkcja gęstości tego rozkładu to

$$f(x) = \frac{1}{2^{k/2}\Gamma(k/2)} \cdot x^{k/2-1} e^{-x/2}, \quad x \in (0, \infty)$$

Dystrybuanta  $G(t)$  rozkładu chi kwadrat jest całką z powyższej funkcji, tj.  $G(t) = \int_0^t f(x) dx$  dla  $t \geq 0$ . Naszym zadaniem jest znalezienie jak najlepszego przybliżenia tej całki. W tym celu użyjemy metod całkowania numerycznego - złożonego wzoru trapezów i metody Romberga.


## Spis treści

<b>1</b>	<b>Złożony wzór trapezów</b>	<b>3</b>
<b>2</b>	<b>Metoda Romberga</b>	<b>4</b>
2.1	Opis metody . . . . .	4
2.2	Uwagi implementacyjne . . . . .	5
<b>3</b>	<b>Wyniki obliczeń</b>	<b>5</b>

# 1 Złożony wzór trapezów

Mając daną funkcję  $f(x)$  na przedziale  $[a, b]$  możemy oszacować jej całkę używając **wzoru trapezów**:


$$\int_a^b f(x) dx \approx (f(a) + f(b)) \cdot \frac{b-a}{2}$$



Źródło: [https://en.wikipedia.org/wiki/Trapezoidal\\_rule](https://en.wikipedia.org/wiki/Trapezoidal_rule)

Rys. 1: Interpretacja geometryczna wzoru trapezów

Metoda polegająca na oszacowaniu całki przez pole jednego trapezu da zawsze dobre przybliżenie jedynie gdy  $f$  jest funkcją liniową - w ogólnym przypadku jest niedokładna. Można jednak zauważyć, że gdyby podzielić przedział  $[a, b]$  na wiele równych, małych podprzedziałów, na każdym z nich policzyć przybliżenie całki wzorem trapezów, a następnie zsumować wyniki z tych podprzedziałów, to wówczas dostaniemy zdecydowanie lepsze przybliżenie całki  $\int_a^b f(x) dx$ . Właśnie na tej idei opiera się **złożony wzór trapezów**.



Źródło: <https://www.math24.net/trapezoidal-rule>

Rys. 2: Interpretacja geometryczna zł. wzoru trapezów

Podzielimy przedział  $[a, b]$  na  $n$  równych podprzedziałów. Niech  $h_n = \frac{b-a}{n}$  oraz  $t_i = a + i h_n$  dla  $0 \leq i \leq n$ . Zgodnie z podaną wyżej intuicją szacujemy

całkę:

$$\begin{aligned}\int_a^b f(x) dx &\approx (f(t_0) + f(t_1)) \frac{h_n}{2} + (f(t_1) + f(t_2)) \frac{h_n}{2} + \dots + (f(t_{n-1}) + f(t_n)) \frac{h_n}{2} = \\ &= h_n \left( \frac{1}{2} f(t_0) + f(t_1) + \dots + f(t_{n-1}) + \frac{1}{2} f(t_n) \right) = h_n \sum_{i=0}^n f(t_i)\end{aligned}$$

gdzie  $\sum''$  - suma, w której pierwszy i ostatni element mnożymy przez  $\frac{1}{2}$ .

Dla wygody wprowadźmy oznaczenie  $T_n(f) := h_n \sum_{i=0}^n f(t_i)$ .

Powyższa metoda daje już dość dobre oszacowanie całki. Pozostaje jedynie zauważyć, że większa liczba podprzedziałów, na które podzielimy  $[a, b]$ , oznacza lepsze przybliżenie, w szczególności  $\lim_{n \rightarrow \infty} T_n(f) = \int_a^b f(x) dx$ .

## 2 Metoda Romberga

### 2.1 Opis metody

Metoda Romberga polega na konstrukcji trójkątnej tablicy (jak poniżej) z wykorzystaniem złożonego wzoru trapezu, a następnie pewnej zależności rekurencyjnej.

$$\begin{array}{ccccccc}T_{0,0} & & & & & & \\T_{0,1} & T_{1,0} & & & & & \\T_{0,2} & T_{1,1} & T_{2,0} & & & & \\T_{0,3} & T_{1,2} & T_{2,1} & T_{3,0} & & & \\ \vdots & \vdots & \vdots & \vdots & \ddots & & \\T_{0,m} & T_{1,m-1} & T_{2,m-2} & T_{3,m-3} & \dots & T_{m,0}\end{array}$$

Pierwszą kolumnę powyższej tablicy wypełniamy korzystając ze złożonego wzoru trapezów (oznaczenia jak w poprzednim rozdziale):

$$T_{0k} = T_{2^k}(f) = h_{2^k} \sum_{i=0}^{2^k} f(t_i)$$

Kolejne elementy tablicy obliczamy korzystając z następującej zależności rekurencyjnej:

$$T_{m,k} = \frac{4^m T_{m-1,k+1} - T_{m-1,k}}{4^m - 1}$$

Po wyznaczeniu wszystkich wartości w tablicy Romberga należy zwrócić jako wynik  $T_{m,0}$  - jest to najlepsze przybliżenie całki. Pozostaje tylko dodać, że im większą liczbę  $m$  ustalimy na początku, tym dokładniejszy wynik uzyskamy.

Korzystając z podanych do tego momentu narzędzi można już zaimplementować algorytm, który będzie obliczał przybliżenie całki zadanej funkcji na określonym przedziale z bardzo dobrą dokładnością. Można jednak wprowadzić pewne ulepszenia, które znacząco poprawią działanie programu.

## 2.2 Uwagi implementacyjne

- **Złożoność pamięciowa.** Naiwna implementacja metody Romberga wymaga użycia trójkątnej tablicy 2-wymiarowej - złożoność jest więc kwadratowa  $O(m^2)$ . Można jednak zauważyć, że do obliczenia kolumny  $i+1$  wystarczy znać jedynie kolumnę  $i$ . Interesuje nas tylko  $T_{m,0}$ , więc nie musimy pamiętać wcześniejszych wartości tablicy. Jeśli będziemy obliczać elementy zaczynając "od dołu" kolumny, to okazuje się, że potrzebna jest nam jedynie 1-wymiarowa tablica rozmiaru  $m$ , czyli dostaniemy w ten sposób złożoność pamięciową  $O(m)$ .
- **Obliczanie wartości funkcji.** Przyjrzyjmy się pierwszej kolumnie tablicy Romberga. Zauważmy, że licząc każdy element bezpośrednio ze wzoru trapezów, wielokrotnie obliczamy wartości funkcji  $f$  dla tych samych argumentów. W szczególności  $f(a)$  i  $f(b)$  zostają policzone aż  $m$  razy, a np.  $f(\frac{b-a}{2}) - m - 1$  razy. Można jednak zastosować następujący lemat na obliczanie kolejnego elementu pierwszej kolumny:

**Lemat.** Niech  $T_n(f)$  oznacza złożony wzór trapezów dla  $n$  podprzedziałów oraz  $M_n(f) = h_n \sum_{i=1}^n f(a + \frac{1}{2}(2i-1)h_n)$ . Wówczas dla  $n = 1, 2, 3 \dots$

$$T_{2n}(f) = \frac{1}{2}(T_n(f) + M_n(f))$$

*Dowód.*

$$\begin{aligned} T_{2n}(f) &= h_{2n} \sum_{i=0}^{2n} f(t_i) = h_{2n} \sum_{i=0}^n f(t_{2i}) + h_{2n} \sum_{i=1}^n f(t_{2i-1}) = \\ &= \frac{1}{2}T_n(f) + h_{2n} \sum_{i=1}^n f(a + (2i-1)h_{2n}) = \frac{1}{2}T_n(f) + \frac{1}{2}h_n \sum_{i=1}^n f(a + \frac{1}{2}(2i-1)h_n) = \\ &= \frac{1}{2}T_n(f) + \frac{1}{2}M_n(f) \end{aligned}$$

□

## 3 Wyniki obliczeń

Dystrybuantę rozkładu  $\chi^2$ , czyli całkę na zadanym przedziale, obliczamy więc za pomocą złożonego wzoru trapezów i metody Romberga. Należy zauważyć, że metoda Romberga daje dokładniejsze wyniki i ma lepsze zastosowanie praktyczne. (Doświadczenie zostało przeprowadzone w języku Python w arytmetyce 64-bitowej.)

**Przykład** dla  $\chi^2(4)$  i  $t = 2$  :

Dokładnym wynikiem jest  $\frac{e-2}{e} = 0.2642411176571153568\dots$

<b>n</b>	<b>Wynik zł. wzoru trapezów</b>	<b>Rząd błędu</b>
$2^1$	0.24360252522101894	$10^{-2}$
$2^2$	0.2590450401914125	$10^{-2}$
$2^3$	0.26293980164730035	$10^{-3}$
$2^4$	0.2639156448023526	$10^{-3}$
$2^5$	0.26415974044776863	$10^{-4}$
$2^6$	0.2642207727924738	$10^{-5}$
$2^7$	0.26423603140580976	$10^{-5}$
$2^8$	0.2642398460920923	$10^{-5}$
$2^9$	0.26424079976572223	$10^{-6}$
$2^{10}$	0.2642410381842585	$10^{-7}$
$2^{11}$	0.26424109778890065	$10^{-7}$
	0.2642411176571153568	0

Powyższa tabela przedstawia wyniki obliczeń dla złożonego wzoru trapezów. Jak widać, błąd zbiega do 0, jednak jest to dość wolna zbieżność. Zdecydowanie lepiej sprawdza się metoda Romberga:

<b>n</b>	<b>Wynik <math>T_{n0}</math> metody Romberga</b>	<b>Rząd błędu</b>
$2^1$	0.2634901267661182	$10^{-3}$
$2^2$	0.2642393730759054	$10^{-5}$
$2^3$	0.26424111672947576	$10^{-9}$
$2^4$	0.26424111765699954	$10^{-11}$
$2^5$	0.2642411176571154	$10^{-16}$
$2^6$	0.26424111765711533	$10^{-16}$
$2^7$	0.2642411176571154	$10^{-16}$
$2^8$	0.2642411176571152	$10^{-16}$
	0.2642411176571153568	0

W tym przypadku błąd zbiega do 0 zdecydowanie szybciej - jedyne co zaczyna nas ograniczać to dokładność reprezentacji liczb w arytmetyce zmiennopozycyjnej. Widzimy więc, że metoda Romberga jest efektywnym narzędziem do aprosymowania całek oznaczonych. W szczególności może mieć zastosowanie w teorii prawdopodobieństwa, gdzie często należy z dużą dokładnością przybliżać dystrybuanty zmiennych losowych.